




INTELIGENCIA ARTIFICIAL

Clase 9

Tutor: José Andrés Montenegro Santos
Viernes, 13 de diciembre de 2024

MODELOS DE MACHINE LEARNING





ENTRENAMIENTO DE MODELOS




¿Qué es?

El término "entrenamiento del modelo de IA" se refiere a este proceso: alimentar los datos del algoritmo, examinar los resultados y ajustar la salida del modelo para aumentar la precisión y la eficacia. Para ello, los algoritmos necesitan cantidades masivas de datos que capturen la gama completa de datos entrantes.

Valores atípicos, sorpresas, inconsistencias, patrones que no tienen sentido a primera vista... los algoritmos deben lidiar con todo esto y más, repetidamente, en todos los conjuntos de datos entrantes. Este proceso es la base del aprendizaje: la capacidad de reconocer patrones, comprender el contexto y tomar decisiones adecuadas. Con suficiente entrenamiento del modelo de IA, el conjunto de algoritmos dentro del modelo representará un predictor matemático para una situación dada que incorpora tolerancias para lo inesperado y maximiza la previsibilidad.



MÉTODOS DE ENTRENAMIENTO



Método de retención

El método de retención para entrenar un modelo de aprendizaje automático es el proceso de dividir los datos en diferentes fracciones y usar una fracción para entrenar el modelo y las otras fracciones para validar y probar los modelos. El método de retención se utiliza tanto para la evaluación como para la selección de modelos.

En lugar de utilizar un conjunto de datos completo para el entrenamiento, se separan o reservan diferentes conjuntos llamados conjunto de validación y conjunto de prueba (y, por lo tanto, se les asigna un nombre de reserva) del conjunto de datos completo y el modelo se entrena solo en lo que se denomina conjunto de datos de entrenamiento .

DATASET

Training Dataset

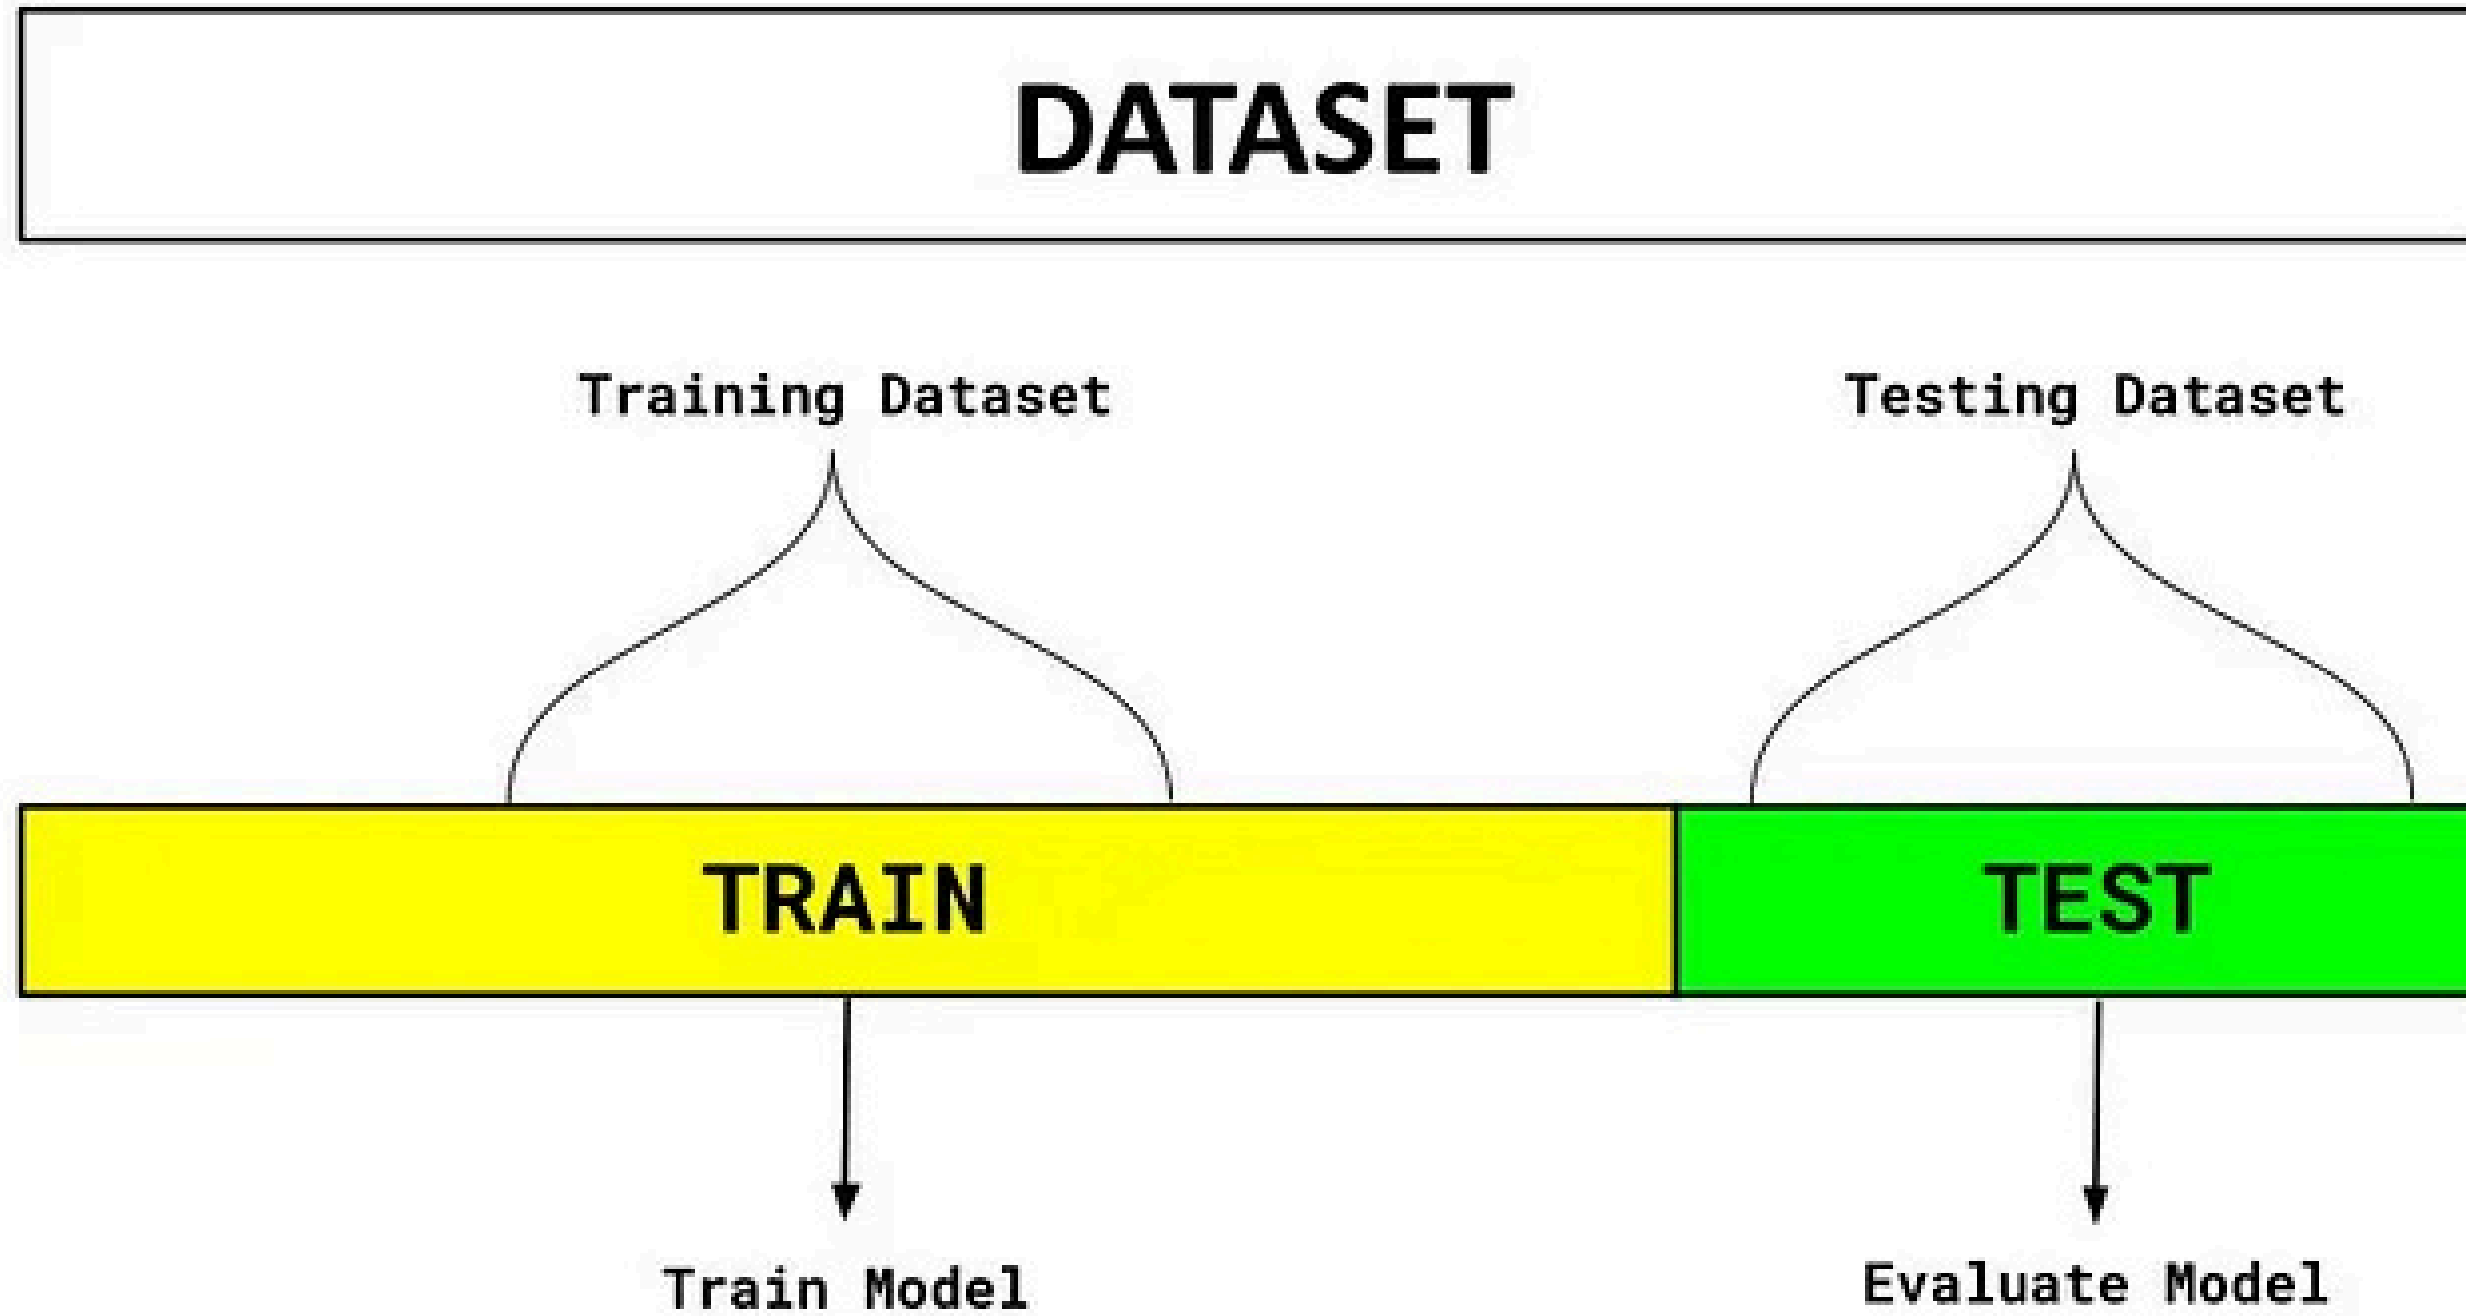
Testing Dataset

TRAIN

TEST

Train Model

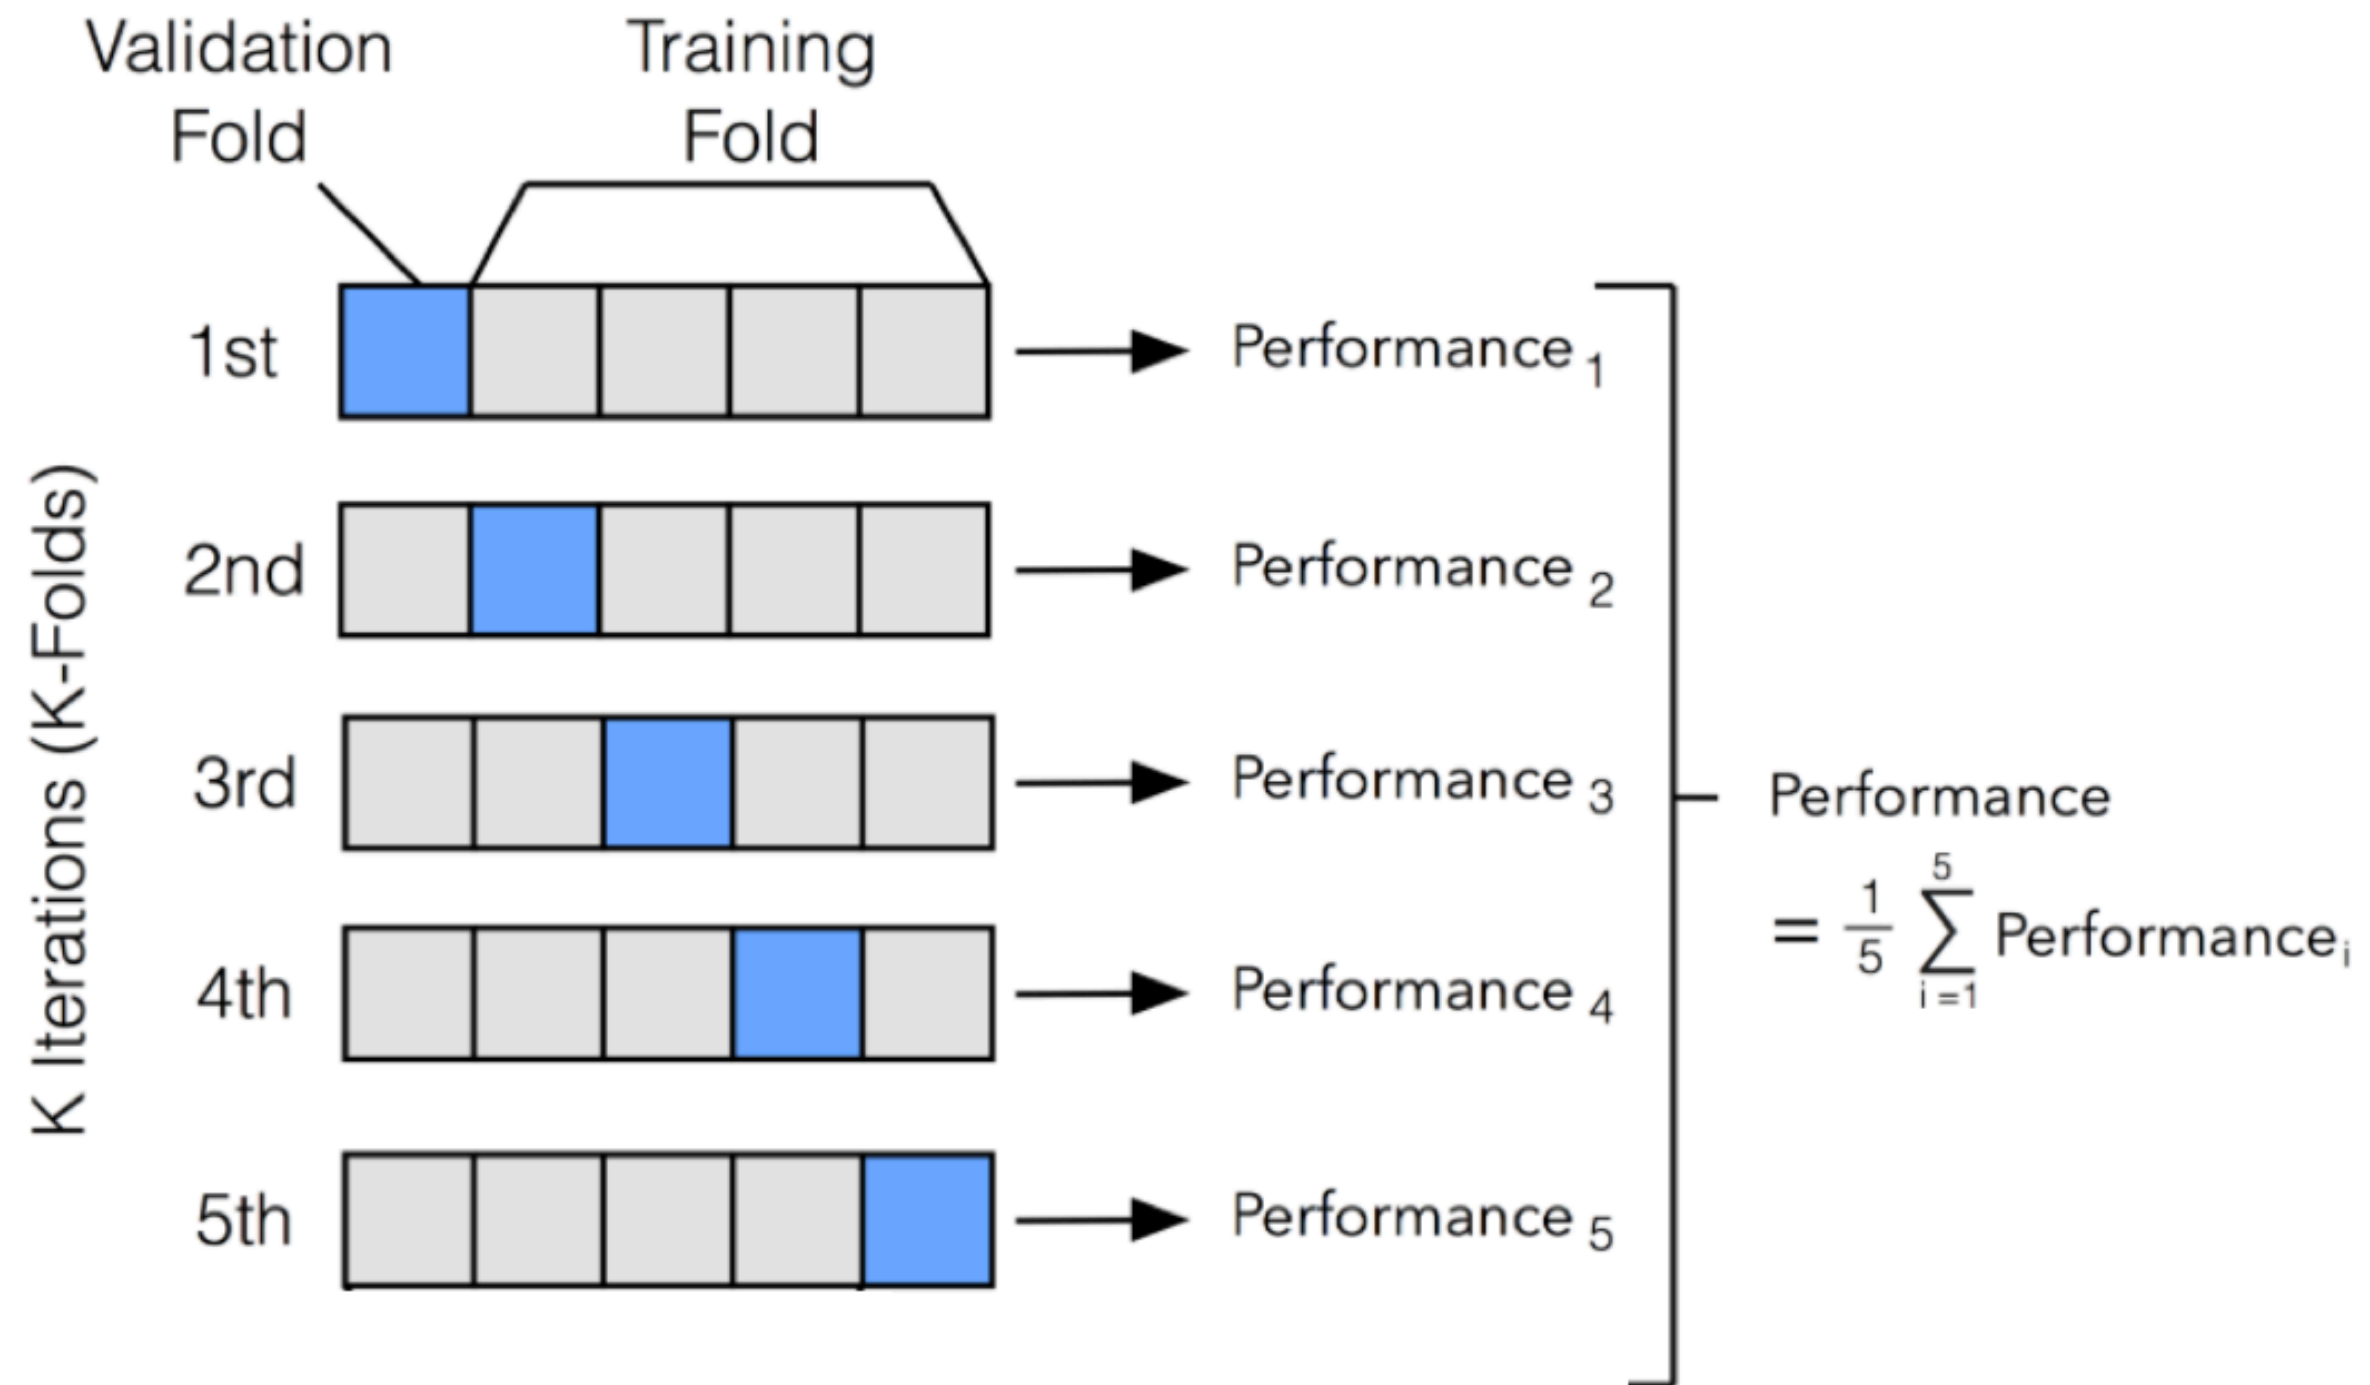
Evaluate Model



Validación cruzada de K iteraciones


En este enfoque -probablemente el más usado- se divide el conjunto de entrenamiento en k bloques, usándose uno de ellos para validación y el resto ($k-1$) para entrenamiento. Rotando el bloque de validación entre los k bloques disponibles, se pueden entrenar k modelos cuyos resultados se combinan tal y como se ha explicado.

k suele tomar típicamente los valores 3, 5 o 10. En general, cuando mayor sea el número de muestras con las que estamos trabajando, menor puede ser el número de bloques en los que dividimos los datos manteniendo la precisión de la estimación.






ALGORITMOS DE APRENDIZAJE AUTOMÁTICO



¿Qué es?

Un algoritmo de aprendizaje automático es un conjunto de reglas o procesos utilizados por un sistema de IA para realizar tareas, la mayoría de las veces para descubrir nuevos conocimientos y patrones de datos, o para predecir valores de salida a partir de un conjunto determinado de variables de entrada. Los algoritmos permiten que el aprendizaje automático (ML) aprenda.





XGBoost

GBoost es la abreviatura de las palabras inglesas "extreme gradient boosting" (refuerzo de gradientes extremo). Este método se basa en árboles de decisión y supone una mejora sobre otros métodos, como el bosque aleatorio y refuerzo de gradientes. Funciona bien con datasets grandes y complejos al utilizar varios métodos de optimización.


K-means

El algoritmo k-means es un método de agrupamiento que divide un conjunto de datos en k grupos o clusters. Los datos se agrupan de tal manera que los puntos en el mismo clúster sean más similares entre sí que los puntos en otros clusters.





EVALUACIÓN DEL MODELO



¿Qué es?


La evaluación de modelos es un proceso crítico en el desarrollo de modelos de aprendizaje automático y consiste en medir y comparar el rendimiento de los modelos para determinar su precisión y eficacia. El objetivo de la evaluación de modelos es determinar si un modelo es capaz de hacer predicciones precisas y consistentes sobre nuevos datos.

En el proceso de evaluación de modelos, se utiliza un conjunto de datos de prueba para probar el modelo y medir su rendimiento en términos de métricas específicas, como la precisión, la sensibilidad, la especificidad y la F1-score, entre otras. Estas métricas permiten determinar cuán bien el modelo se desempeña en la tarea para la cual se ha entrenado.

Además de las métricas de rendimiento, también se pueden utilizar técnicas de validación cruzada para evaluar la capacidad del modelo para generalizar a nuevos datos. Esto se hace dividiendo el conjunto de datos en varios subconjuntos de entrenamiento y prueba y evaluando el modelo en cada subconjunto para determinar su capacidad para hacer predicciones precisas en datos no vistos.

Matriz de confusión

Una matriz de confusión (o matriz de error) es un método de visualización para los resultados del algoritmo clasificador. Más específicamente, es una tabla que desglosa el número de instancias reales de una clase específica frente al número de instancias previstas para esa clase. Las matrices de confusión son una de las varias métricas de evaluación que miden el rendimiento de un modelo de clasificación. Se pueden utilizar para calcular otras métricas de rendimiento del modelo, como la precisión y la coincidencia, entre otras



Sensibilidad

Se refiere a la probabilidad de que el resultado de la prueba de una enfermedad sea positivo si realmente tiene la enfermedad. A medida que aumente la sensibilidad de una prueba, disminuirá la cantidad de personas que tienen la enfermedad, pero cuyas pruebas tengan resultado negativo (negativos falsos).

Especificidad

Se refiere a la probabilidad de que los resultados de una prueba sean negativos si realmente no tiene la enfermedad. A medida que aumente la especificidad de una prueba, disminuirá la cantidad de personas que no tienen la enfermedad, pero cuyas pruebas tienen resultado positivo (positivos falsos).

$$\text{Sensibilidad} = \frac{\text{Verdaderos Positivos}}{\text{Verdaderos positivos} + \text{Falsos Negativos}} \times 100$$

$$\text{Sensibilidad} = \frac{333}{333 + 13} \times 100 = 96.24\%$$

$$\text{Especificidad} = \frac{\text{Verdaderos Negativos}}{\text{Verdaderos Negativos} + \text{Falsos Positivos}} \times 100$$

$$\text{Especificidad} = \frac{23}{23 + 16} \times 100 = 58.97 \%$$

Precisión

Se entiende como la medida de los casos positivos correctamente identificados de entre todos los casos positivos previstos. Por lo tanto, resulta útil cuando el coste de los falsos positivos es elevado.

Accuracy

Una de las métricas más obvias, es la medida de todos los casos identificados correctamente. Se utiliza más cuando todas las clases son igualmente importantes.

$$\text{Precision} = \frac{\text{True Positive}}{(\text{True Positive} + \text{False Positive})} = \frac{25}{(25+5)} = \frac{25}{30} = 0.83$$

Precisión

$$\text{Accuracy} = \frac{\text{True Positive} + \text{True Negative}}{(\text{True Positive} + \text{False Positive} + \text{True Negative} + \text{False Negative})}$$

Puntuación F1

Es la media armónica de precisión y sensibilidad y ofrece una mejor medida de los casos clasificados incorrectamente que la métrica de precisión.

$$\text{F1-score} = \left(\frac{\text{Recall}^{-1} + \text{Precision}^{-1}}{2} \right)^{-1} = 2 * \frac{(\text{Precision} * \text{Recall})}{(\text{Precision} + \text{Recall})}$$


Puntuación F1

Accuracy vs Puntuación F1



La precisión se utiliza cuando los verdaderos positivos y los verdaderos negativos son más importantes, mientras que la puntuación F1 se utiliza cuando los falsos negativos y los falsos positivos son cruciales.

La precisión se puede utilizar cuando la distribución de clases es similar, mientras que la puntuación F1 es una mejor métrica cuando hay clases desequilibradas como en el caso anterior.

En la mayoría de los problemas de clasificación de la vida real, existe una distribución de clases desequilibrada y, por lo tanto, la puntuación F1 es una mejor métrica para evaluar nuestro modelo.



AJUSTE DE HIPERPARÁMETROS




¿Que son?

Los hiperparámetros son variables de configuración que los científicos de datos establecen de antemano para gestionar el proceso de entrenamiento de un modelo de aprendizaje automático. La IA generativa y demás modelos probabilísticos aplican sus aprendizajes a partir de los datos de entrenamiento para predecir el resultado más probable de una tarea. Encontrar la combinación adecuada de hiperparámetros es esencial para obtener el mejor rendimiento de los modelos de aprendizaje supervisado y no supervisado.

El ajuste de hiperparámetros consiste en identificar y seleccionar los hiperparámetros óptimos para el entrenamiento de un modelo de aprendizaje automático. Cuando se realiza correctamente, el ajuste de hiperparámetros minimiza la función de pérdida de un modelo de aprendizaje automático, lo que significa que el rendimiento del modelo se entrena para ser lo más preciso posible

Hiperparámetros relacionados con el modelo



1

Redes neuronales

En el aprendizaje profundo, los hiperparámetros clave relacionados con el modelo incluyen la cantidad de capas, las neuronas en cada capa y las funciones de activación. Por ejemplo, agregar más capas puede permitir que un modelo capture patrones más complejos, pero también puede aumentar el costo computacional y el riesgo de sobreajuste.

2

Máquinas de vectores de soporte


Los hiperparámetros importantes incluyen el tipo de kernel (lineal, polinomial, RBF), que determina cómo el algoritmo asigna los datos de entrada a dimensiones superiores, y el parámetro de margen (C), que controla el equilibrio entre maximizar el margen y minimizar los errores de clasificación.

3

Árboles de decisión

Los hiperparámetros como la profundidad máxima del árbol y las muestras mínimas necesarias para dividir un nodo controlan la complejidad del árbol y ayudan a prevenir el sobreajuste. Elegir los hiperparámetros correctos relacionados con el modelo es fundamental, ya que estos determinan las capacidades fundamentales del modelo.

Hiperparámetros relacionados con el entrenamiento



1

Tamaño del lote

Esto determina cuántas muestras procesa el modelo a la vez antes de actualizar los pesos. Los tamaños de lote más pequeños ofrecen actualizaciones más precisas, mientras que los lotes más grandes brindan eficiencia computacional.

2

Número de épocas

Esto define la frecuencia con la que se pasa todo el conjunto de datos a través del modelo durante el entrenamiento. Demasiadas épocas pueden provocar un sobreajuste, mientras que muy pocas pueden provocar un subajuste. La gestión adecuada de estos hiperparámetros es crucial para lograr resultados de aprendizaje eficientes y estables.